Auto-évaluation

Renforcez vos fondamentaux de Python pour la Data Science en analysant les données de systèmes éducatifs

Exercice en 3 parties - Analysez des données de systèmes éducatifs



Un dernier doute ?

Pour vérifier la qualité de votre travail :

- cochez les cases ci-dessous : elles indiquent que vous avez bien pris en compte chaque indicateur de réussite ;
- complétez votre fiche au fur et à mesure de votre progression dans votre exercice.
- renseignez, si besoin, la colonne “Notes” avec des commentaires sur vos livrables / vos étapes. Ils seront des points de discussion avec votre mentor pendant votre session de bilan / soutenance.

Quand toutes les cases de ce document seront cochées, vous pourrez déposer vos livrables sur la plateforme.

Bonne réussite !

Compétences	Indicateurs de réussite de l’activité	Notes
Appliquer des analyses statistiques descriptives et / ou naviguer visuellement au sein des données afin de détecter des anomalies.	▣ J’ai vérifié que l’installation de JupyterLab (ou un équivalent) était fonctionnelle. ▣ J’ai importé Pandas, Matplotib et Seaborn sans erreur au sein du Notebook. ▣ Je suis capable d’expliquer ce que représente chaque ligne dans chaque jeu de données. ▣ J’ai calculé la taille des jeux de données avec Pandas. ▣ J’ai décrit le contenu des colonnes de chaque jeu de données en utilisant les méthodes fournies par Pandas.	

Supprimer / corriger les anomalies manuellement et à l'aide d'outils / logiciels de nettoyage des données adaptés.	■ J'ai calculé le nombre de doublons avec Pandas et les ai supprimés. ■ J'ai quantifié les valeurs manquantes par colonne dans les jeux de données. ■ Mon traitement des valeurs manquantes est en cohérence avec la problématique métier. ■ J'ai utilisé les filtrages à base de conditions de Pandas : ■ pour supprimer les faux pays ; ■ pour réduire le nombre d'indicateurs via une colonne contenant des catégories d'indicateurs. ■ Ma matrice de corrélation est cohérente : ■ elle a été calculée avec Pandas ; ■ visualisée avec Seaborn ; ■ utilisée pour filtrer les indicateurs redondants. ■ Je suis capable d'expliquer le sens des coefficients de corrélation de Pearson et de Spearman. ■ Je suis satisfait de l'utilisation des markdown.	
Appliquer des analyses statistiques descriptives et / ou naviguer visuellement au sein des données afin de détecter des anomalies.	■ J'ai utilisé la méthode group_by() de Pandas pour évaluer la qualité des indicateurs et des années (en termes de valeurs renseignées). ■ J'ai utilisé la méthode pivot_table() pour créer un jeu de données avec : ■ comme lignes : des pays ; ■ comme colonne : des indicateurs ; ■ comme valeurs : des résultats d'agrégations d'années.	
	■ Je suis satisfait de mon interprétation des résultats de la méthode describe() de Pandas.	

	◼ J’ai rendu visuelles et interprété les distributions d’une variable quantitative en utilisant Seaborn ou Matplotlib. ◼ J’ai nommé mes variables en respect des bonnes pratiques. ◼ J’ai implémenté au moins une fonction pour automatiser un traitement présent plusieurs fois dans le code. ◼ J’ai utilisé au moins une boucle for pour éviter de répéter manuellement un traitement/une analyse.	
Configurer l’environnement de travail nécessaire à l’exploitation des données	◼ J’ai installé Poetry. ◼ J’ai créé et rempli un fichier pyproject.toml en utilisant poetry init et/ou poetry add. ◼ Le code de mon Notebook fonctionne correctement au sein de l’environnement virtuel que j’ai créé.	
Présenter ses résultats	◼ Je suis satisfait de mon rappel du contexte métier au centre de toutes les analyses. ◼ Je présente de manière précise le contenu de chaque fichier de données. ◼ Je présente mes démarches pour nettoyer le jeu de données et réduire le nombre d’indicateurs, tout en précisant les hypothèses sous-jacentes. ◼ Je suis satisfait de mon utilisation des graphiques et ai inclus des axes et des titres lisibles pour présenter mes analyses statistiques quand cela était pertinent. ◼ Je me suis efforcé de clarifier le lien entre mes résultats et l’objectif métier pour un interlocuteur de faible niveau technique. ◼ Je suis satisfait par le storytelling de ma présentation.	