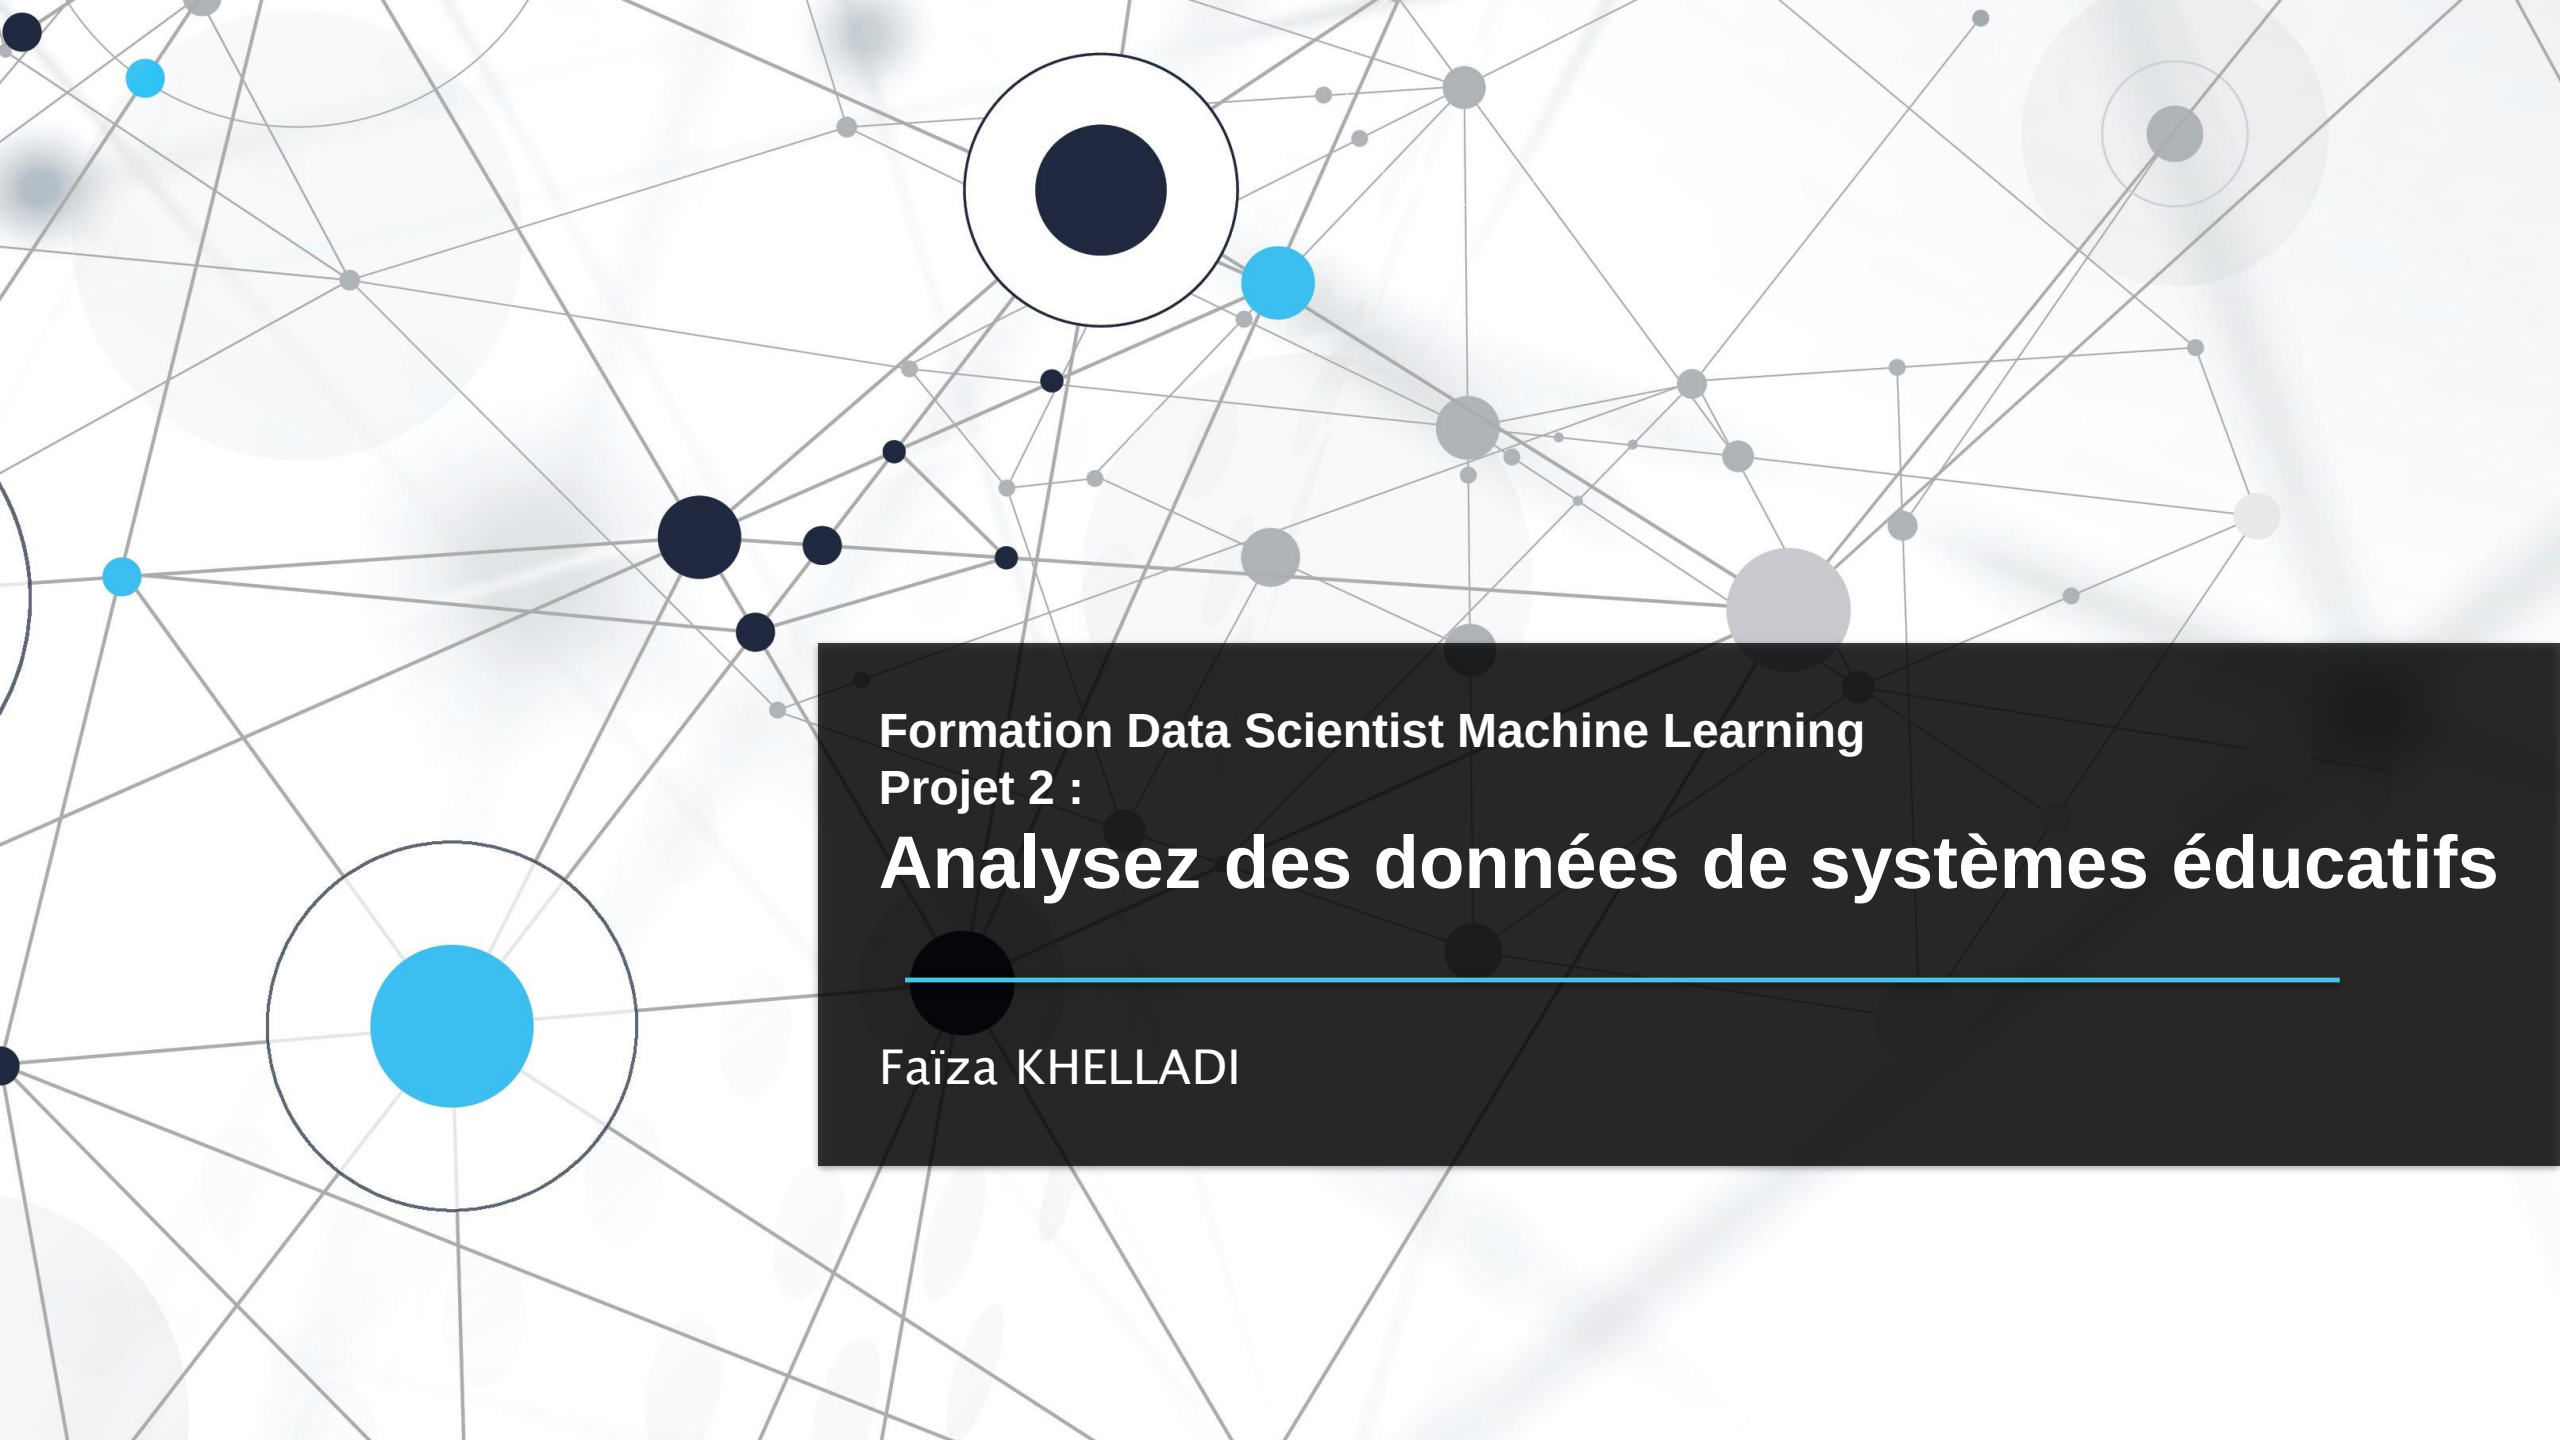


Formation Data Scientist Machine Learning
Projet 2 :

Analysez des données de systèmes éducatifs

Faïza KHELLADI

Context

Academy
Start-up EdTech



Lycéens & étudiants

Projet d'expansion internationale



Quels pays ont un fort potentiel de clients ?



Analyse de données de la banque mondiale

Choix stratégiques d'implantation

Sommaire

- Processus d’identification des pays
- Données de la Banque Mondiale
- Identification de pays avec un fort potentiel
    - Nettoyage de données
    - Choix des indicateurs - Données de la Banque Mondiale
    - Filtrage de données
    - Analyse statistique des données relatives aux indicateurs
    - Classement des pays à fort potentiel
- Recommandations stratégiques pour l’implantation
- Conclusion et perspectives

Processus d’identification des pays

Identification du besoin d’Academy

- Accès aux matériel informatique et à internet
- Qualité modérée du système éducatif
- Facilité d’accès à l’enseignement
- Economie modérée du pays

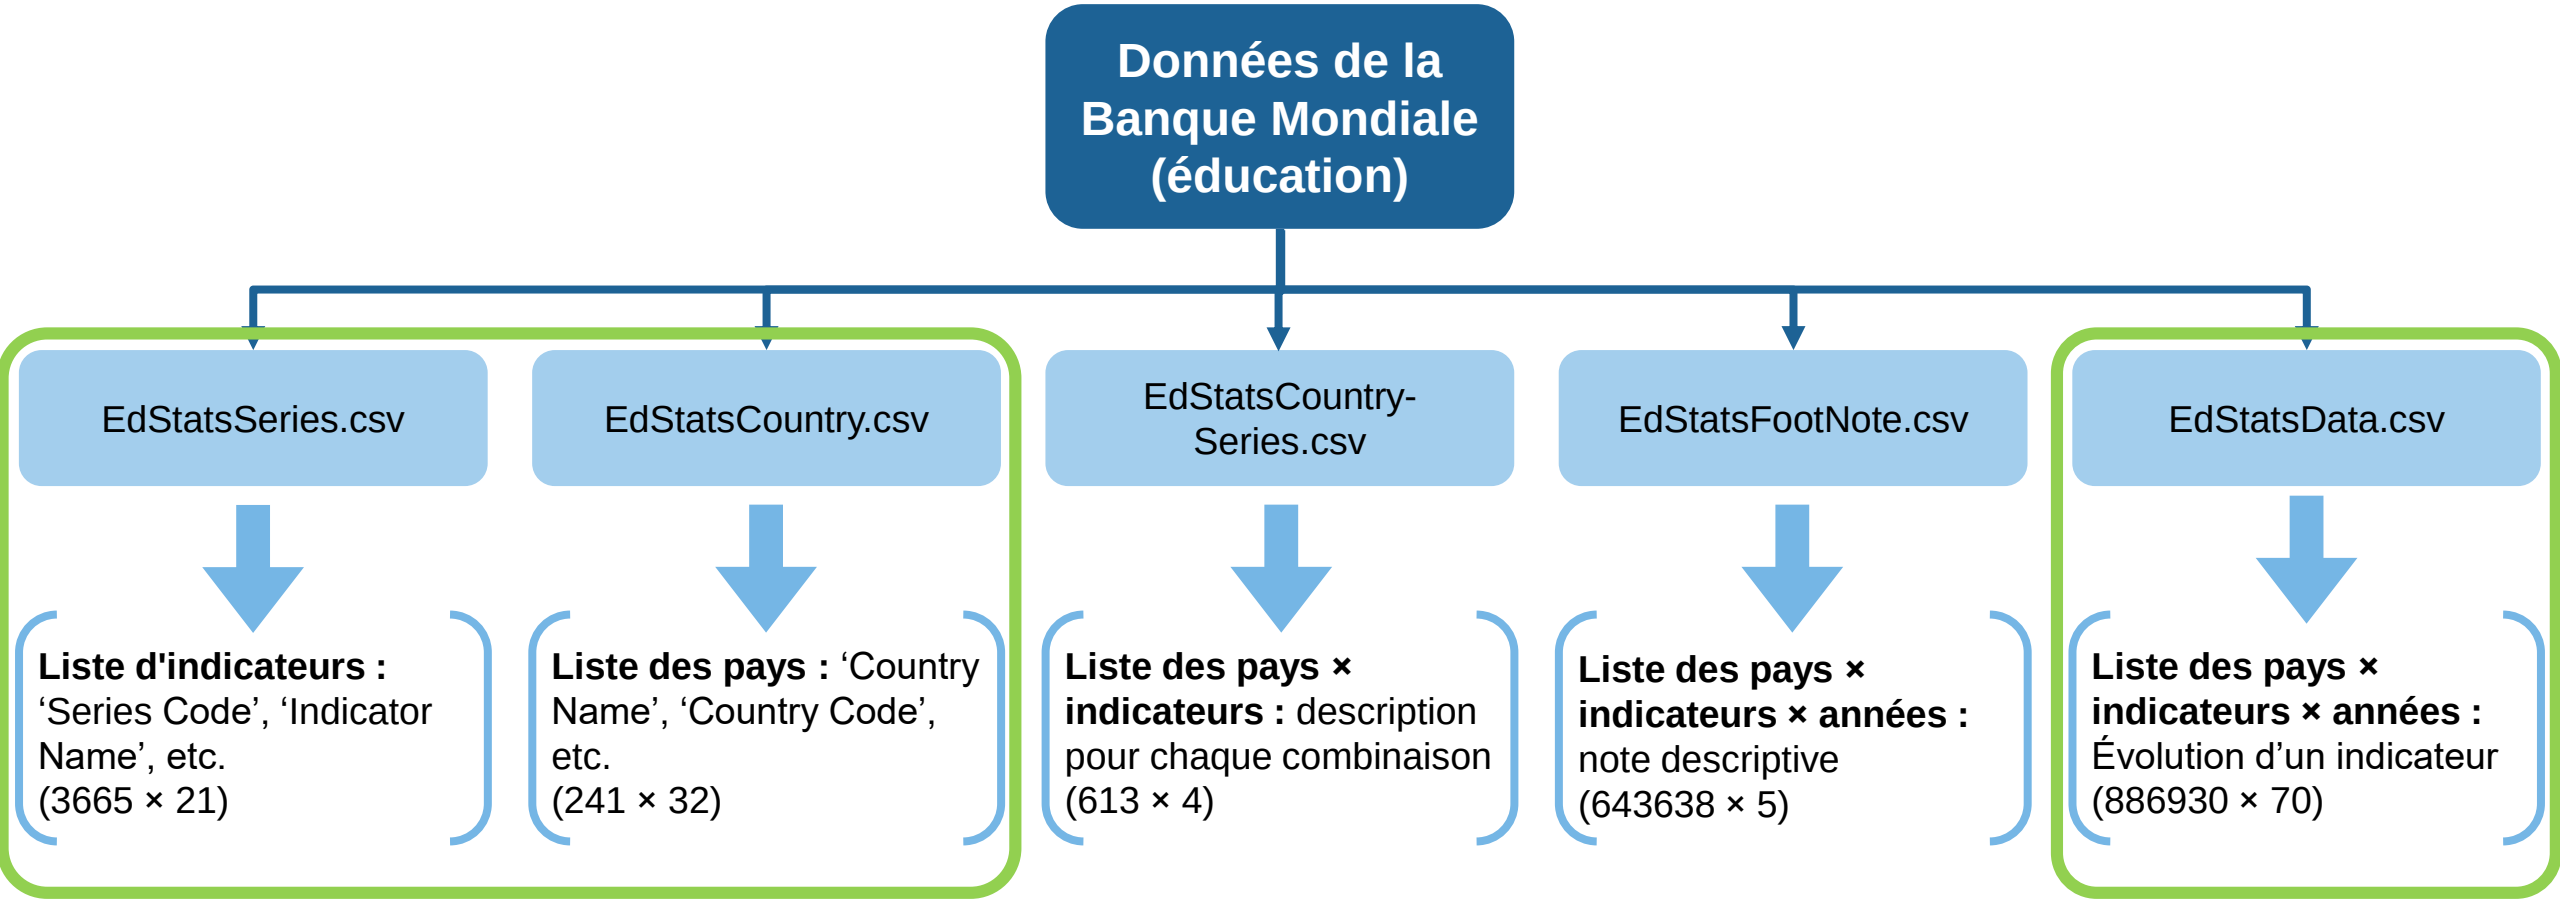
Identification de pays avec un fort potentiel

- Sélection d’indicateurs (Banque Mondiale)
- Analyse statistique des données relatives aux indicateurs
- Classement des pays à fort potentiel

Décisions stratégiques d’implantation

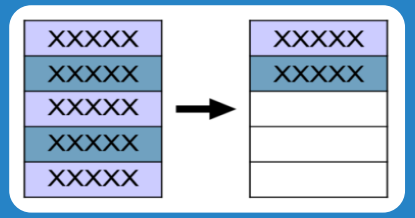
- Conclusion de l’analyse statistique et recommandations pour le projet d’implantation

Données de la Banque Mondiale



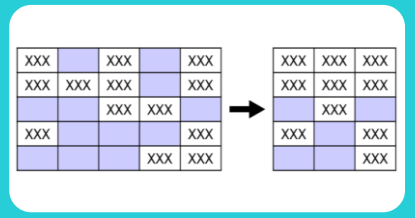
Identification de pays avec un fort potentiel

Nettoyage de données



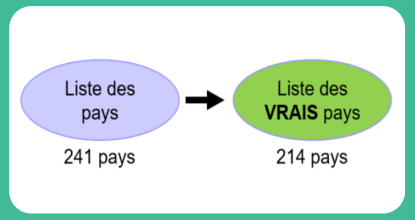
Traitement des doublons

- Identification des lignes dupliquées
- Suppression des doublons
- Le fichier EdStatsSeries.csv contient une liste **unique** d'indicateurs



Traitement des valeurs manquantes (VM)

- Calcul de proportions de valeurs manquantes par colonne
- Suppression de colonnes vides ou dont le taux VM est sup. à un seuil défini



Traitement des faux pays (EdStatsCountry.csv)

- Définition d'un masque d'identification de faux pays : "2-alpha code" manquant ou non valide, "Region" manquante,
- Suppression des faux pays du fichier EdStatsCountry.csv
- Fusion (right join) avec le fichier EdStatsData.csv pour garder les données des vrais pays

Identification de pays avec un fort potentiel

Choix des indicateurs (1/2)

3665 indicateurs regroupés en 37 "Topic"

9 "Topic" sélectionnés

Attainment
Background
EMIS
Early Child Development (SABER)
Early Childhood Education
Economic Policy & Debt: National accounts: Atlas GNI & GNI per capita
Economic Policy & Debt: National accounts: US$ at constant 2010 prices: Aggregate indicators
Economic Policy & Debt: National accounts: US$ at current prices: Aggregate indicators
Economic Policy & Debt: Purchasing power parity
Education Equality
Education Management Information Systems (SABER)
Engaging the Private Sector (SABER)
Expenditures
Health: Mortality
Health: Population: Dynamics
Health: Population: Structure
Health: Risk factors
Infrastructure: Communications
Laber
Learning Outcomes
Literacy
Population
Post-Secondary/Non-Tertiary
Pre-Primary
Primary
School Autonomy and Accountability (SABER)
School Finance (SABER)
School Health and School Feeding (SABER)
Secondary
Social Protection & Labor: Labor force structure
Social Protection & Labor: Unemployment
Student Assessment (SABER)
Teachers
Teachers (SABER)
Tertiary
Tertiary Education (SABER)
Workforce Development (SABER)

Besoin d'Academy	"Topic" sélectionnés
Accès aux matériel informatique et à internet	Infrastructure: Communications
Qualité modérée du système éducatif	Learning Outcomes Teachers
Facilité d'accès à l'enseignement	Post-Secondary/Non-Tertiary Secondary Tertiary
Economie modérée du pays	Economic Policy & Debt: National accounts: Atlas GNI & GNI per capita Economic Policy & Debt: National accounts: US$ at current prices: Aggregate indicators Expenditures

Identification de pays avec un fort potentiel

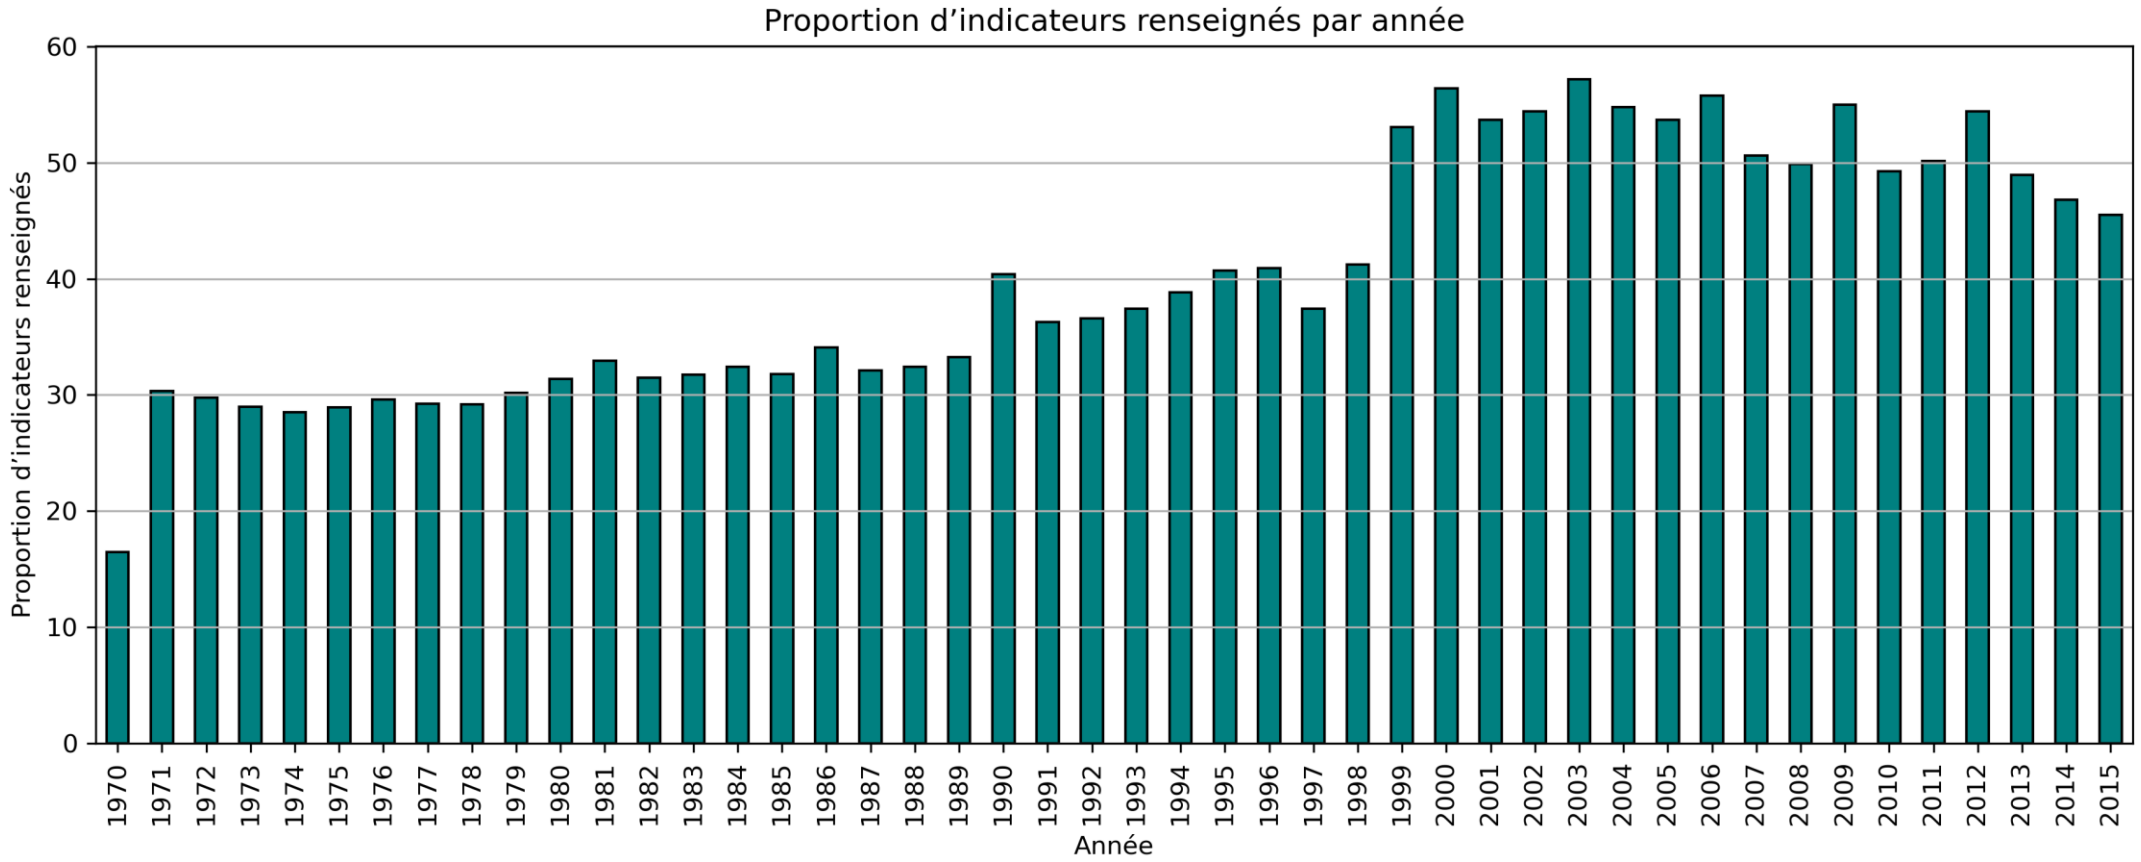
Choix des indicateurs (2/2)

17 indicateurs sélectionnés

Besoin d'Academy	"Topic" sélectionnés	Indicateurs sélectionnés
Accès aux matériels informatiques et à internet	Infrastructure: Communications	Personal computers (per 100 people) Internet users (per 100 people)
Qualité modérée du système éducatif	Learning Outcomes Teachers	PISA: Mean performance on the mathematics scale PISA: Mean performance on the reading scale PISA: Mean performance on the science scale Teachers in secondary education, both sexes (number) Teachers in tertiary education programmes, both sexes (number)
Facilité d'accès à l'enseignement	Post-Secondary/Non-Tertiary Secondary Tertiary	Gross enrolment ratio, secondary, both sexes (%) Enrolment in secondary education, both sexes (number) Gross enrolment ratio, tertiary, both sexes (%) Enrolment in tertiary education, all programmes, both sexes (number) Gross enrolment ratio, post-secondary non-tertiary, both sexes (%) Enrolment in post-secondary non-tertiary education, private institutions, both sexes (number)
Economie modérée du pays	Economic Policy & Debt: National accounts: Atlas GNI & GNI per capita Economic Policy & Debt: National accounts: US$ at current prices: Aggregate indicators Expenditures	GNI per capita, Atlas method (current US$) GDP per capita (current US$) GDP (current US$) Government expenditure on education as % of GDP (%)

Identification de pays avec un fort potentiel

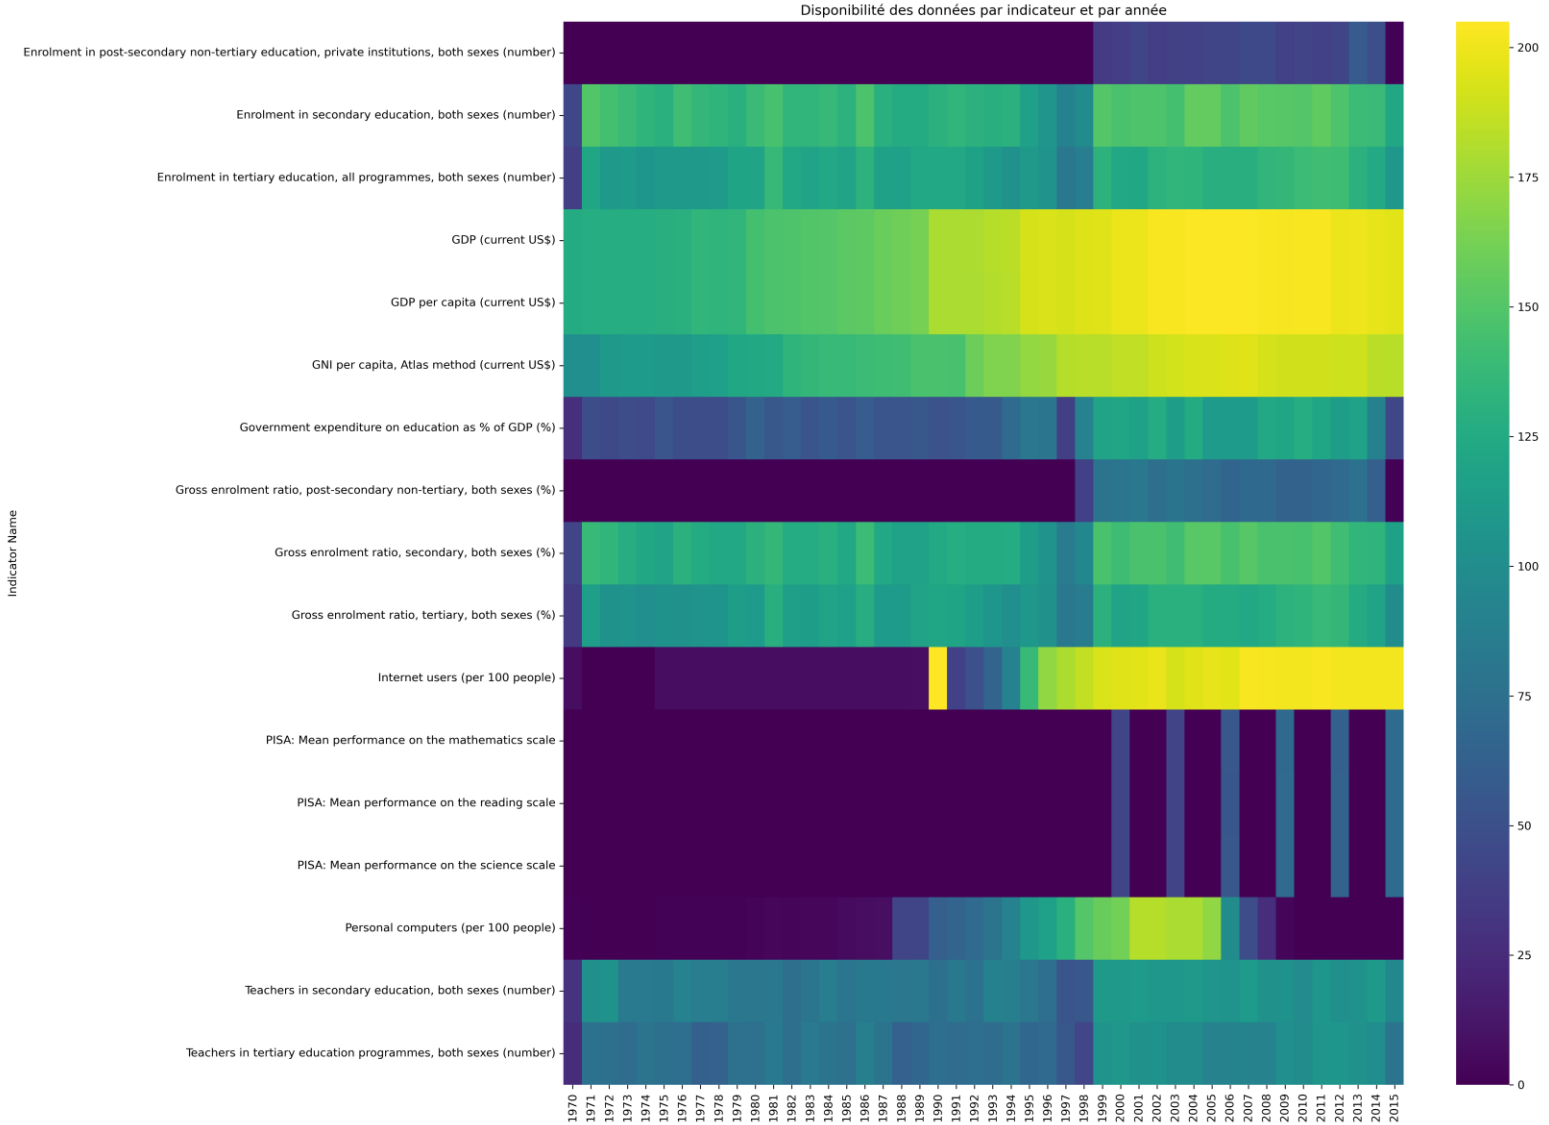
Filtrage des données : Proportion d'indicateurs avec valeurs renseignées



- Pourcentage de données renseignées par année, tous indicateurs confondus < 60%
- Données plus riches à partir de 1999

Identification de pays avec un fort potentiel

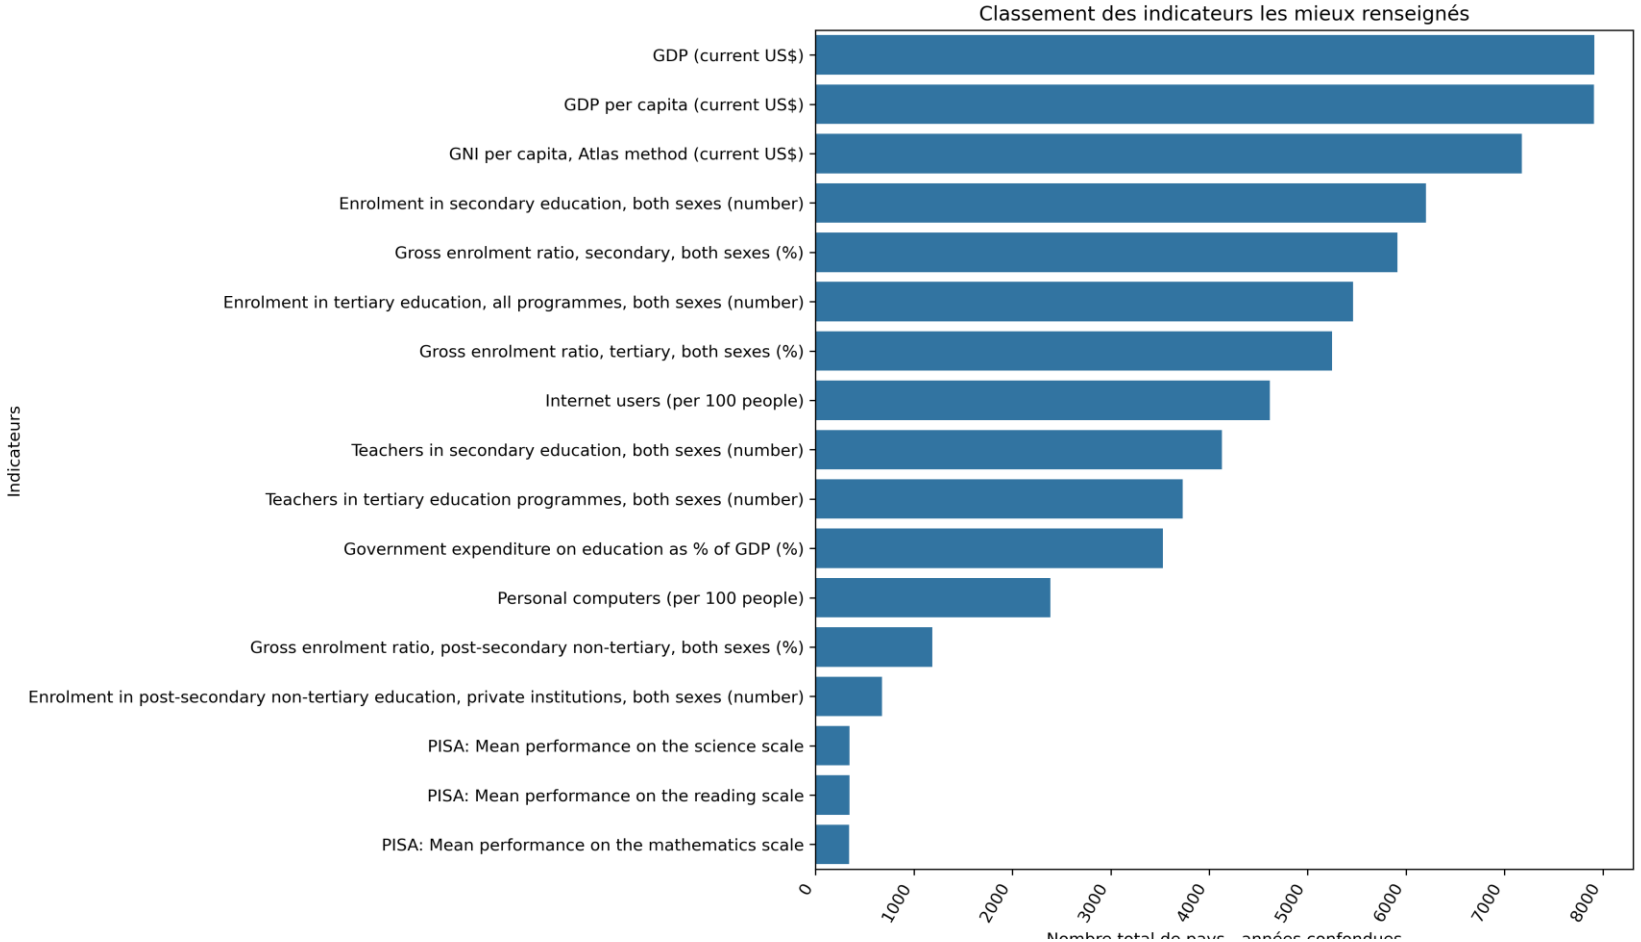
Filtrage des données : Nombre de pays avec données renseignées



- Heatmap du nombre de pays avec des données renseignées par indicateur et par année
- Indicateurs mal renseignés (moins pertinents), car pas connu/répertorié dans beaucoup de pays :
  - Gross enrolment ratio, post-secondary non-tertiary, both sexes (%)
  - Enrolment in post-secondary non-tertiary education, private institutions, both sexes (number)

Identification de pays avec un fort potentiel

Filtrage des données : Indicateurs les mieux renseignés

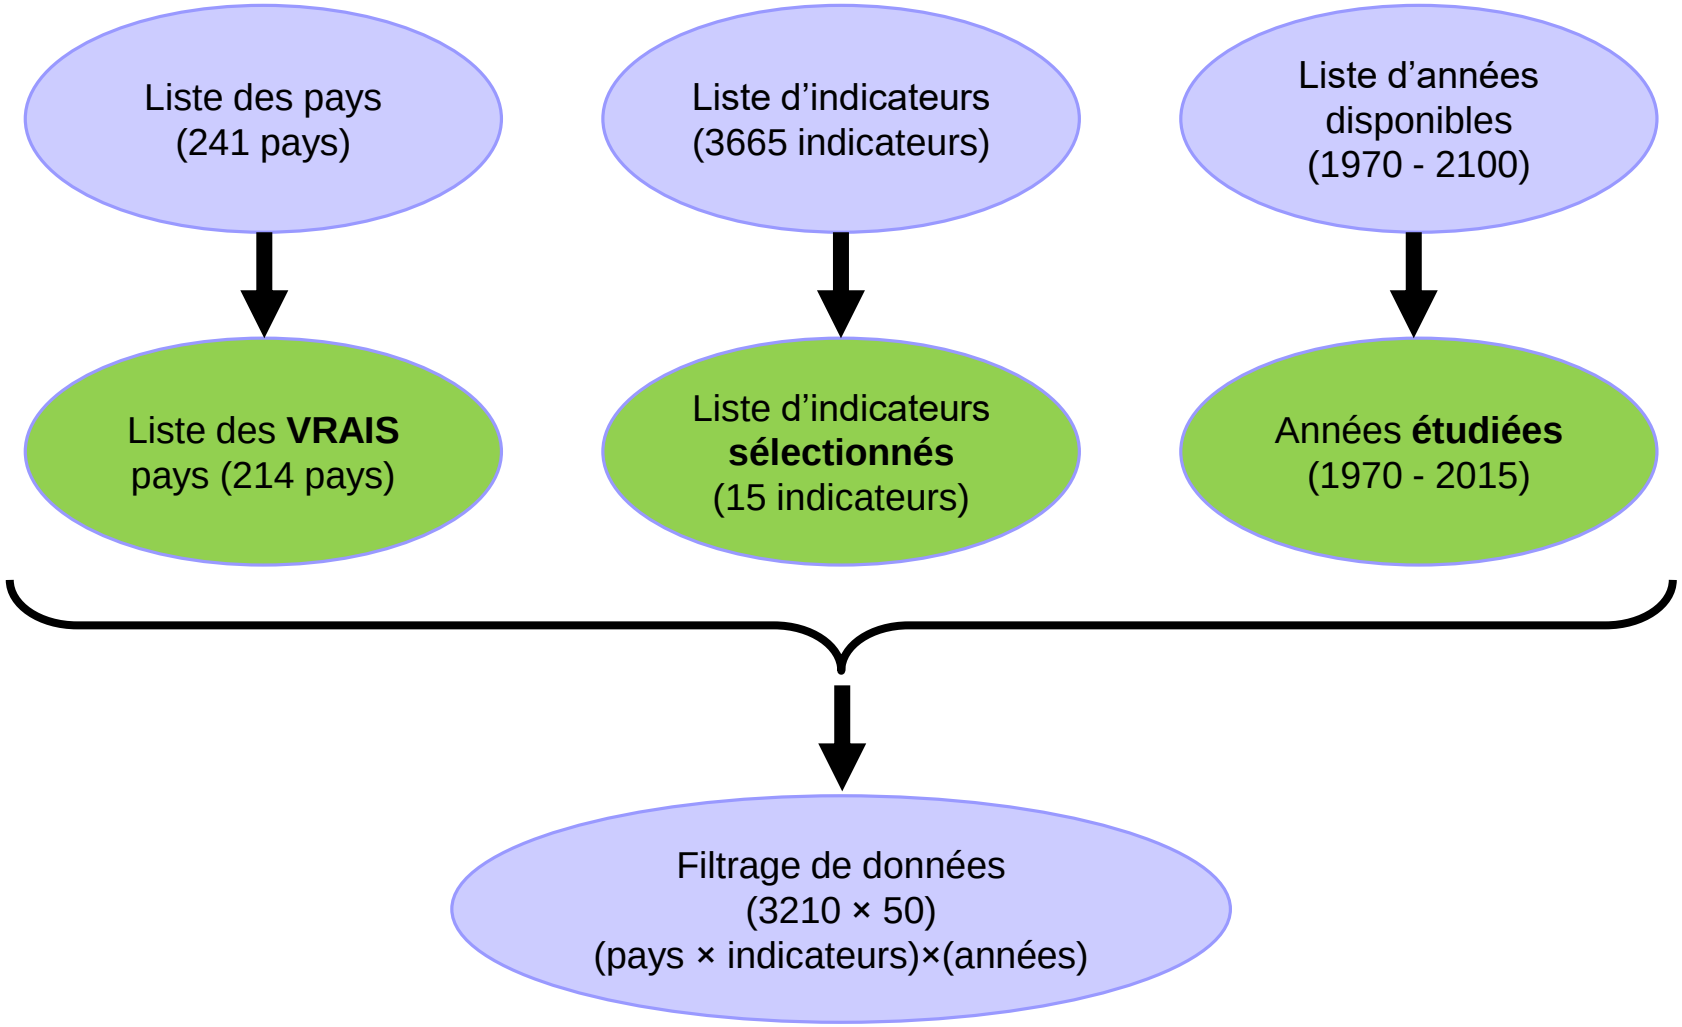


- Indicateurs mal renseignés (moins pertinents), car pas connu/répertorié dans beaucoup de pays :
  - `Gross enrolment ratio, post-secondary non-tertiary, both sexes (%)`
  - `Enrolment in post-secondary non-tertiary education, private institutions, both sexes (number)`

À supprimer de la liste des 17 indicateurs sélectionnés

Identification de pays avec un fort potentiel

Filtrage des données : Vrais pays, indicateurs choisis, années choisies



Identification de pays avec un fort potentiel

Analyse statistique : Construction d'un dataframe issu du filtrage

15 indicateurs

181 pays

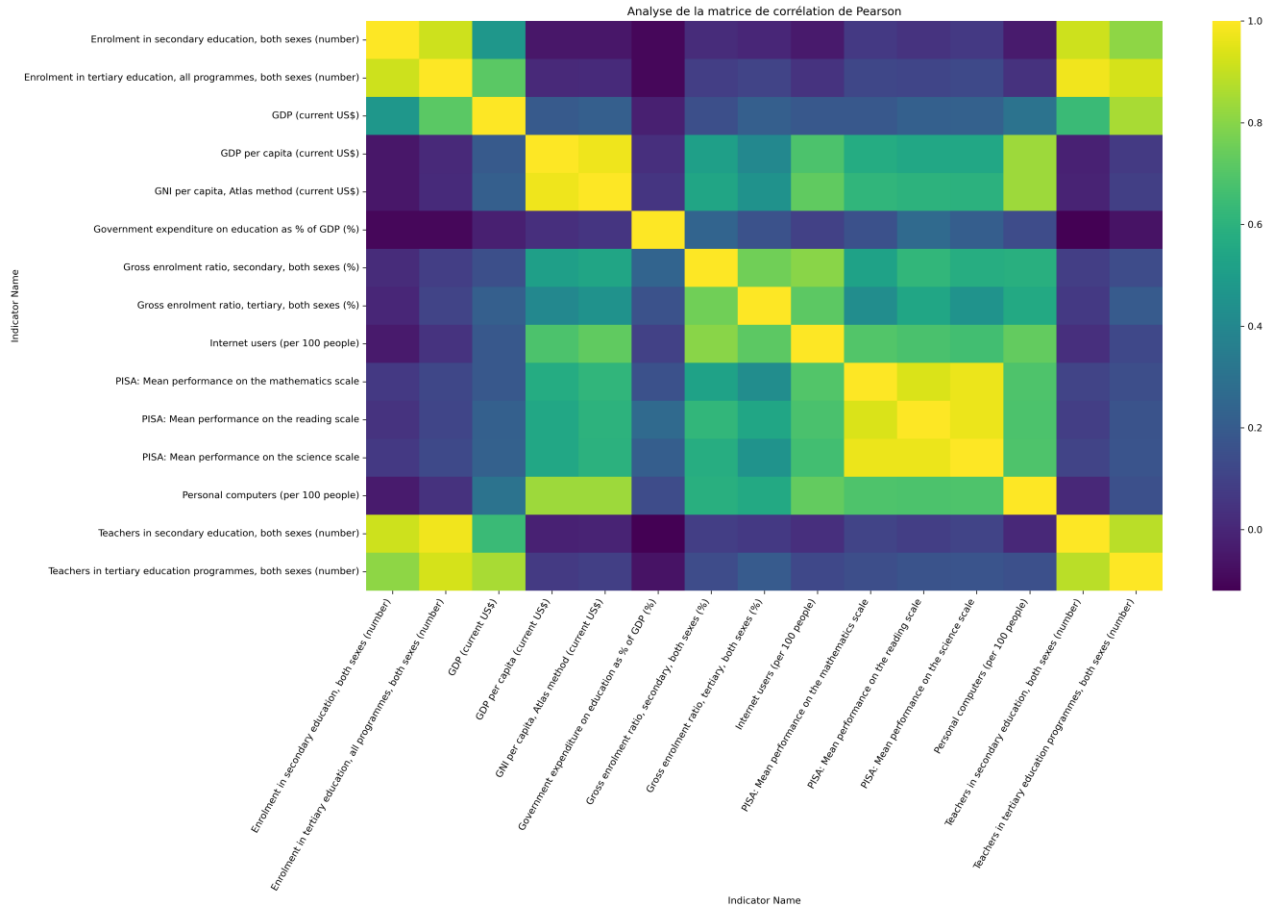
Indicator Name / Country Name	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	GDP (current US$)	GDP per capita (current US$)	GNI per capita, Atlas method (current US$)	Government expenditure on education as % of GDP (%)	Gross enrolment ratio, secondary, both sexes (%)	Gross enrolment ratio, tertiary, both sexes (%)	Internet users (per 100 people)	PISA: Mean performance on the mathematics scale	PISA: Mean performance on the reading scale	PISA: Mean performance on the science scale
Afghanistan	2698816.0	97504.0	1.921556e+10	569.577923	590.0	3.31754	55.644409	3.755980	8.260000	NaN	NaN	NaN
Albania	315079.0	160527.0	1.133526e+10	3934.895394	4290.0	3.53944	95.765488	58.109951	63.252933	413.1570	405.2588	427.225(
Algeria	4572513.0	1289474.0	1.658743e+11	4160.220067	4800.0	4.35425	93.070030	36.922279	29.500000	359.6062	349.8593	375.7451
American Samoa	NaN	1607.0	6.590000e+08	11865.963232	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Andorra	4395.0	501.0	2.811489e+09	36038.267604	NaN	3.25368	NaN	NaN	96.910000	NaN	NaN	NaN

- Récupération de la dernière valeur renseignée par indicateur et par pays
- 181 pays à analyser disposant d'au moins 70% de données sur l'ensemble des indicateurs

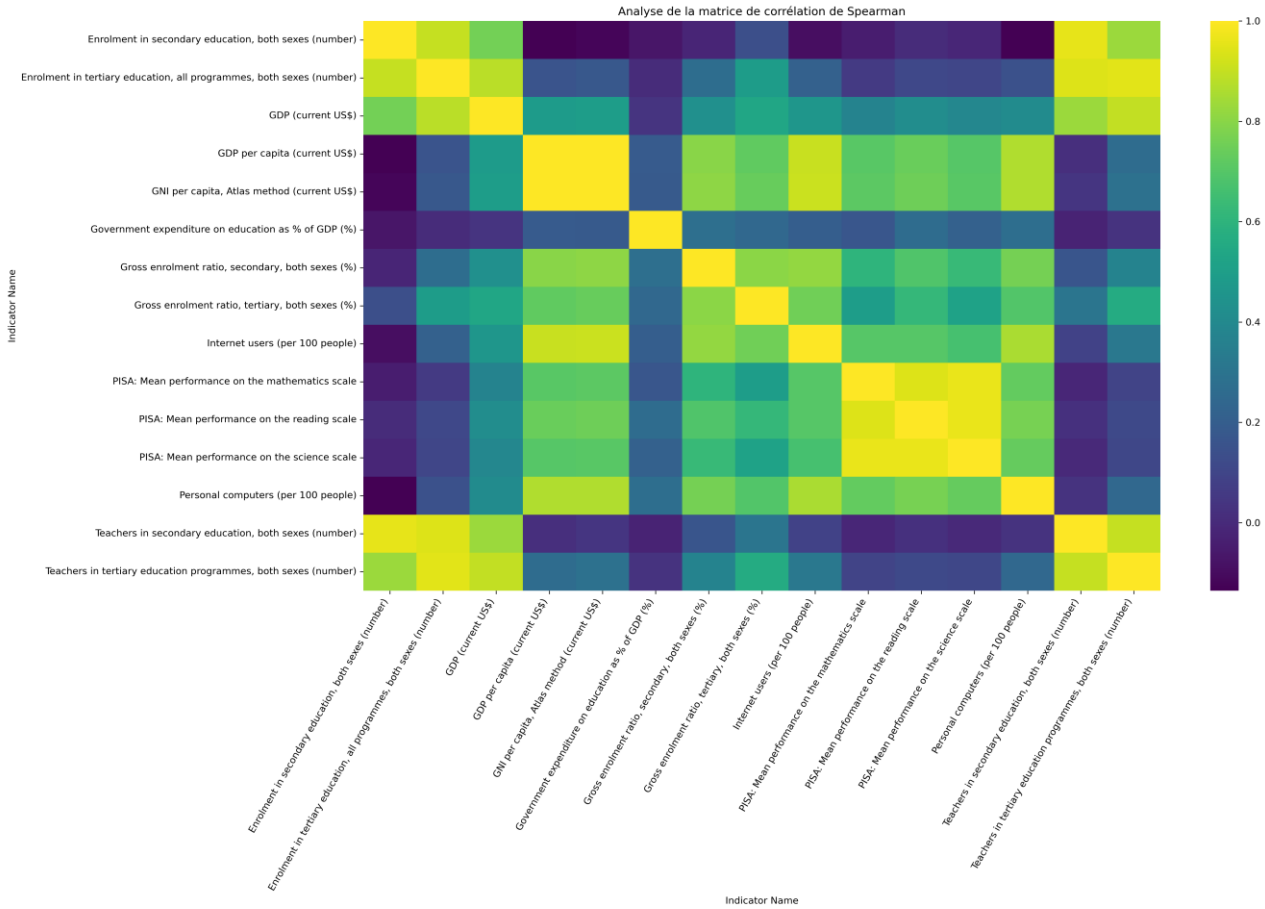
Identification de pays avec un fort potentiel

Analyse statistique : Calcul de la matrice de corrélation

Pearson



Spearman



Identification de pays avec un fort potentiel

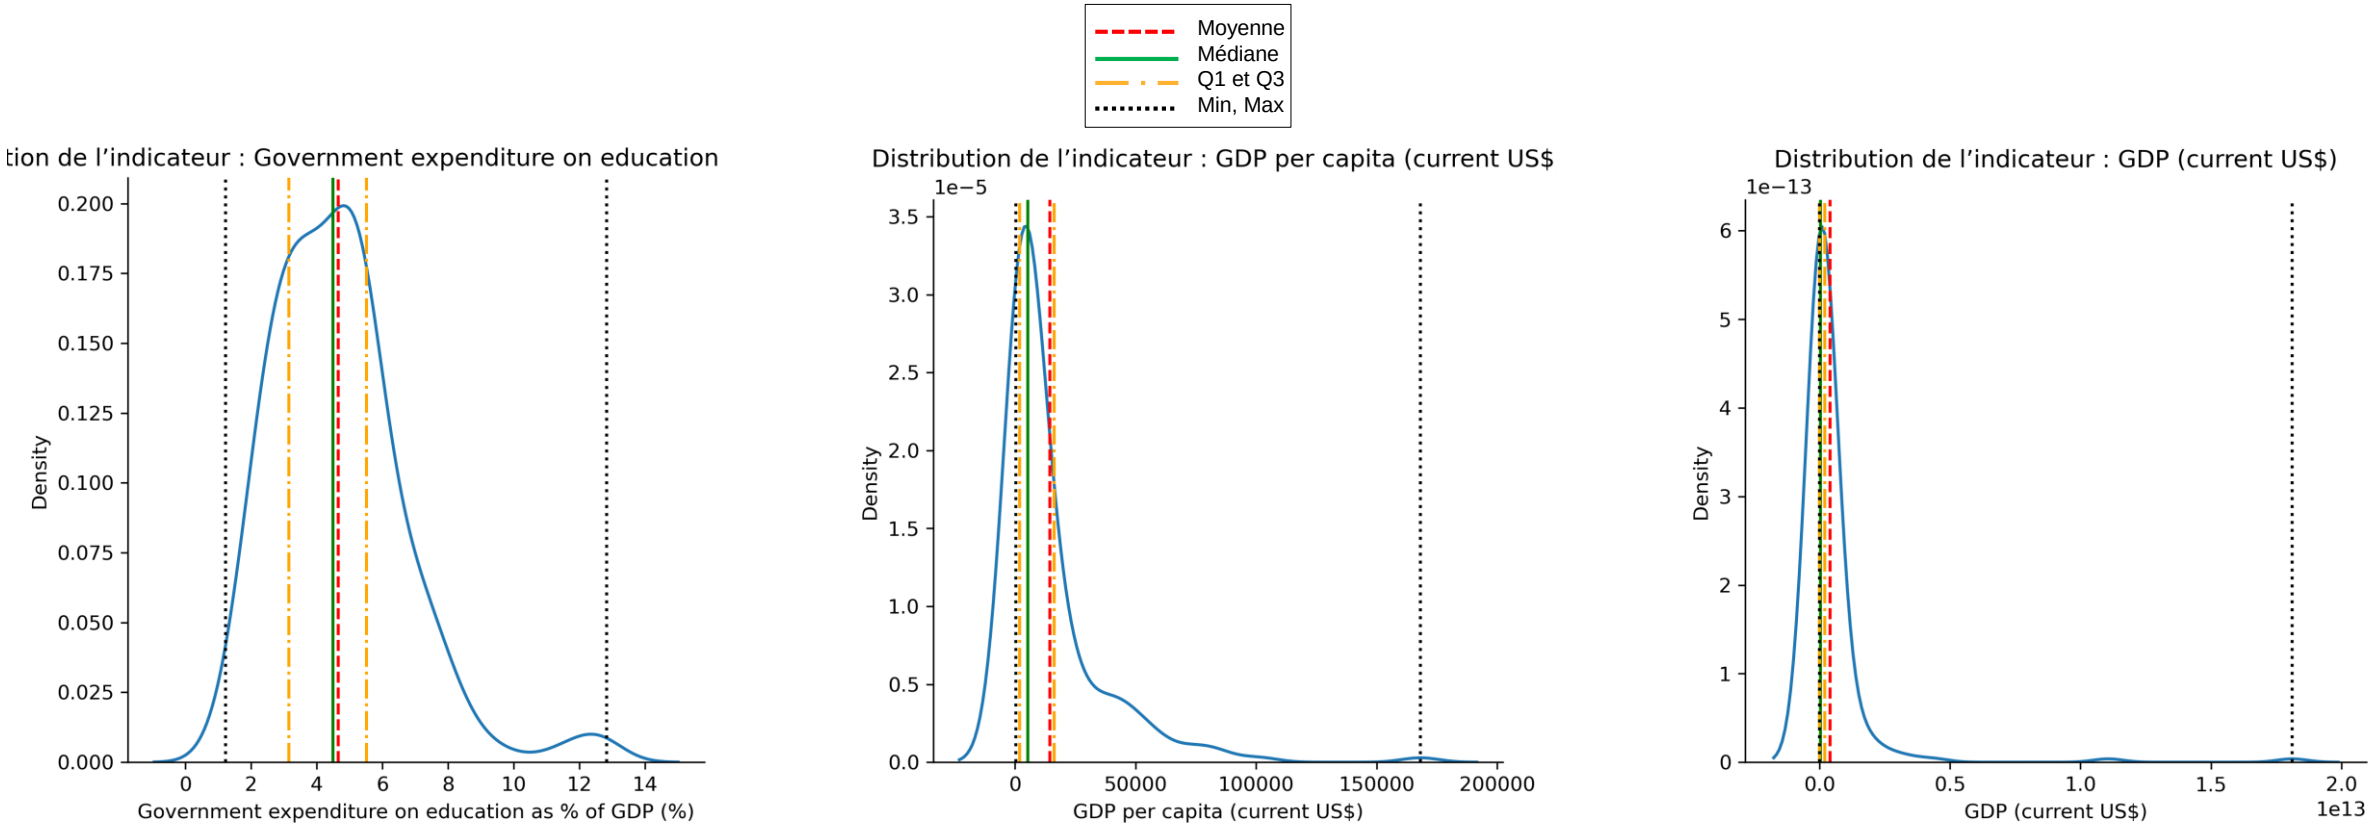
Analyse statistique : Calcul de la matrice de corrélation > 0,7

Indicator Name	Enrolment in secondary education, both sexes (number)	Enrolment in tertiary education, all programmes, both sexes (number)	GDP (current US$)	GDP per capita (current US$)	GNI per capita, Atlas method (current US$)	Government expenditure on education as % of GDP (%)	Gross enrolment ratio, secondary, both sexes (%)	Gross enrolment ratio, tertiary, both sexes (%)	Internet users (per 100 people)	PISA: Mean performance on the mathematics scale	PISA: Mean performance on the reading scale	PISA: Mean performance on the science scale	Personal computers (per 100 people)	Teachers in secondary education, both sexes (number)	Teachers in tertiary education programmes, both sexes (number)
Enrolment in secondary education, both sexes (number)	1.0	0.900833	-	-	-	-	-	-	-	-	-	-	-	0.957057	0.830239
Enrolment in tertiary education, all programmes, both sexes (number)	0.900833	1.0	0.883126	-	-	-	-	-	-	-	-	-	-	0.938263	0.948099
GDP (current US$)	-	0.883126	1.0	-	-	-	-	-	-	-	-	-	-	-	0.894058
GDP per capita (current US$)	-	-	-	1.0	0.996732	-	-	-	-	-	-	-	0.863472	-	-
GNI per capita, Atlas method (current US$)	-	-	-	0.996732	1.0	-	-	-	-	-	-	-	0.866298	-	-
Government expenditure on education as % of GDP (%)	-	-	-	-	-	1.0	-			-	-	-	-	-	-
Gross enrolment ratio, secondary, both sexes (%)	-	-	-	-	-	-			053	-	-	-	-	-	-
Gross enrolment ratio, tertiary, both sexes (%)	-	-	-	-	-		1.0	0.753065		-	-	-	-	-	-
Internet users (per 100 people)	-	-	-	-	0.9		0.753065	1.0		-	-	-	0.855412	-	-
PISA: Mean performance on the mathematics scale	-	-	-	-			-	-	-	1.0	0.941479	0.962589	-	-	-
PISA: Mean performance on the reading scale	-	-	-	-	-	-	-	-	-	0.941479	1.0	0.961792	-	-	-
PISA: Mean performance on the science scale	-	-	-	-	-	-	-	-	-	0.962589	0.961792	1.0	-	-	-
Personal computers (per 100 people)	-	-	-	0.863472	0.866298	-	-	-	0.855412	-	-	-	1.0	-	-
Teachers in secondary education, both sexes (number)	0.957057	0.938263	-	-	-	-	-	-	-	-	-	-	-	1.0	0.902072
Teachers in tertiary education programmes, both sexes (number)	0.830239	0.948099	0.894058	-	-	-	-	-	-	-	-	-	-	0.902072	1.0

Suppression des indicateurs excessivement corrélés

Identification de pays avec un fort potentiel

Analyse statistique : Distribution des indicateurs (1/3)



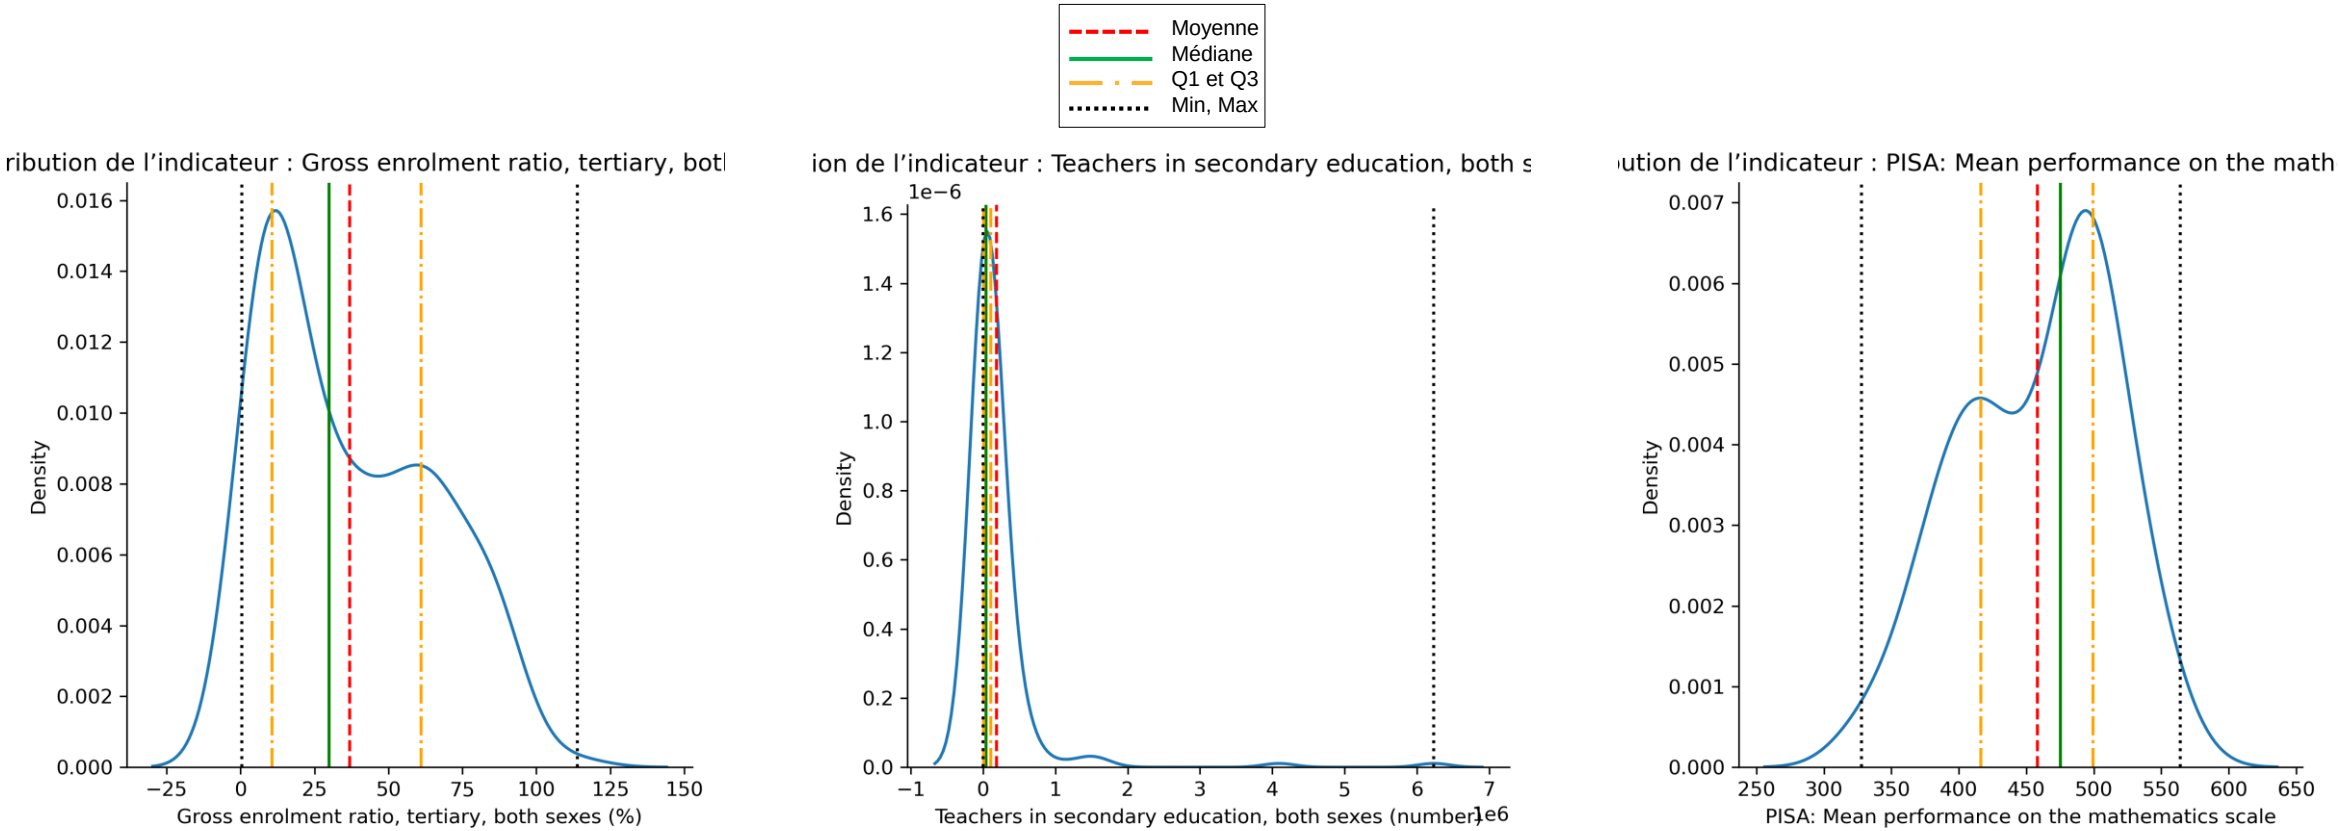
mean	4.661616
std	2.032780
min	1.223930
25%	3.149380
50%	4.495750
75%	5.520422
max	12.837270

mean	14385.990778
std	22074.788851
min	300.676557
25%	1862.167274
50%	5237.255334
75%	16132.860310
max	168146.015281

mean	4.072088e+11
std	1.656829e+12
min	1.796979e+08
25%	8.767144e+09
50%	3.751741e+10
75%	1.950787e+11
max	1.812071e+13

Identification de pays avec un fort potentiel

Analyse statistique : Distribution des indicateurs (2/3)



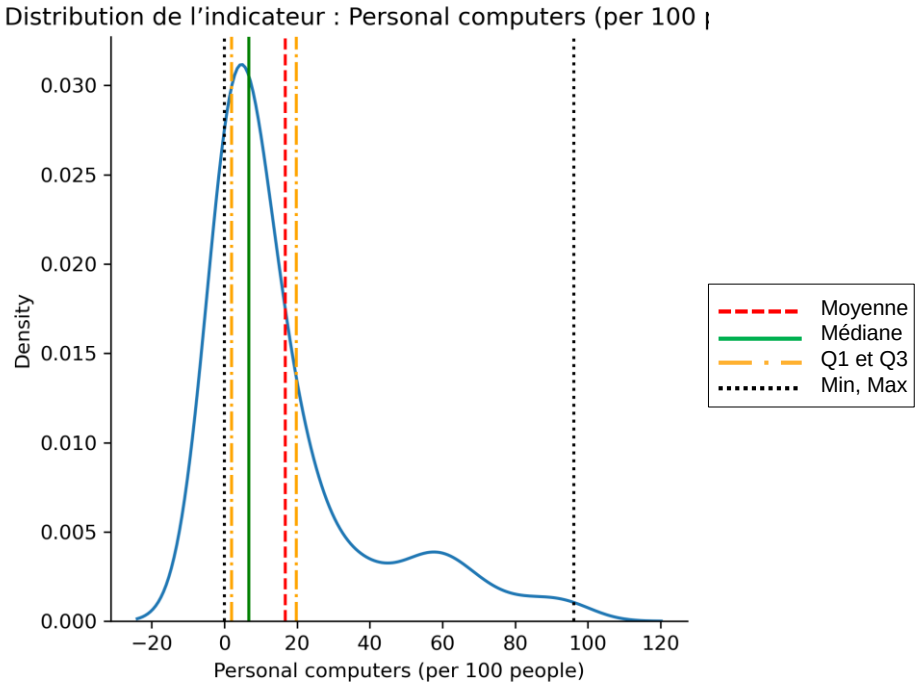
mean	36.979117
std	28.363712
min	0.482130
25%	10.737645
50%	29.940901
75%	61.124575
max	113.871788

mean	1.843981e+05
std	6.167042e+05
min	1.260000e+02
25%	1.002000e+04
50%	3.922400e+04
75%	1.061190e+05
max	6.234124e+06

mean	458.365704
std	56.592136
min	327.702000
25%	416.353600
50%	475.230100
75%	499.236050
max	564.189700

Identification de pays avec un fort potentiel

Analyse statistique : Distribution des indicateurs (3/3)



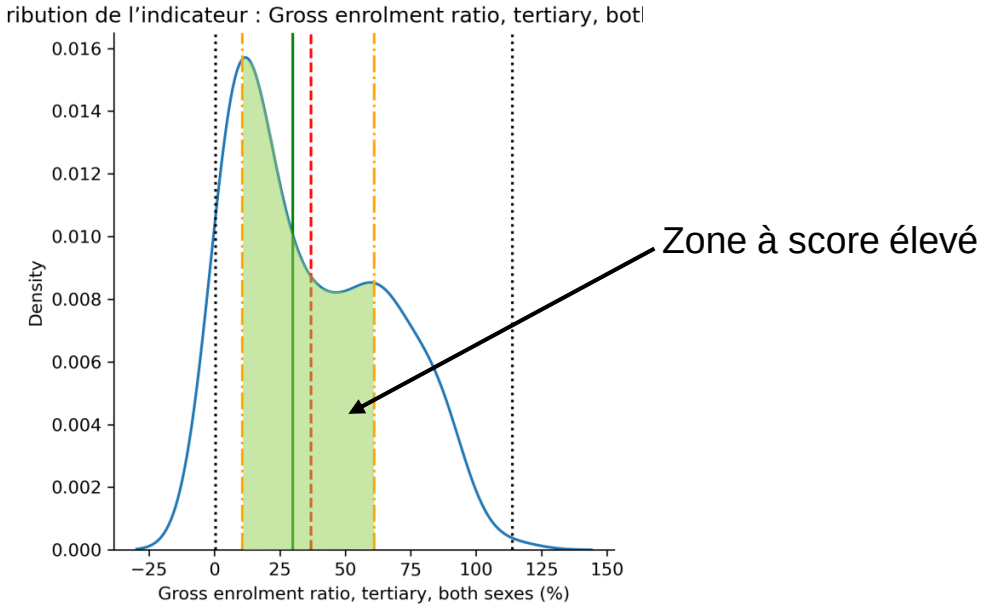
mean	16.737271
std	22.463955
min	0.022211
25%	1.979126
50%	6.698709
75%	19.731152
max	96.170657

Recommandations stratégiques pour l'implantation

Calcul de scores pour les indicateurs

- Choix de pays ayant un système éducatif modéré et une économie stable
- Indicateurs mieux scorés entre Q1 et Q3
- Proposition de calcul de score pour chaque indicateur :

$$score_{indicateur} = \begin{cases} \dfrac{valeur_{indicateur} - Q_1}{Q_3 - Q_1} & si\ valeur_{indicateur} \geq Q_1\ \&\ valeur_{indicateur} \leq Q_3 \\ 0 & sinon \end{cases}$$



Recommandations stratégiques pour l'implantation

Classement des pays avec un fort potentiel : Score final par pays

Méthode 1

- Calcul d'une moyenne de score des indicateurs pour chaque pays :

$$score_{final_{pays}} = \frac{\sum_{i=1}^{nombre\ d'indicateurs} score_{indicateur_i}}{nombre\ d'indicateurs}$$

Hungary	0.738724
Slovak Republic	0.535563
Serbia	0.519990
Romania	0.504497
Croatia	0.488386

Méthode 2

- Calcul de la somme des scores des indicateurs × pondérations :

Indicateur	Pondération w
Gross enrolment ratio, tertiary, both sexes (%)	0,2
PISA: Mean performance on the mathematics scale	0,2
Government expenditure on education as % of GDP (%)	0,15
Personal computers (per 100 people)	0,2
Teachers in secondary education, both sexes (number)	0,05
GDP per capita (current US$)	0,15
GDP (current US$)	0,05

$$score_{final_{pays}} = \sum_{i=1}^{nombre\ d'indicateurs} score_{indicateur_i} \times w_i$$

Hungary	0.763551
Serbia	0.579668
Slovak Republic	0.565524
Romania	0.545185
France	0.528512

5 meilleurs pays

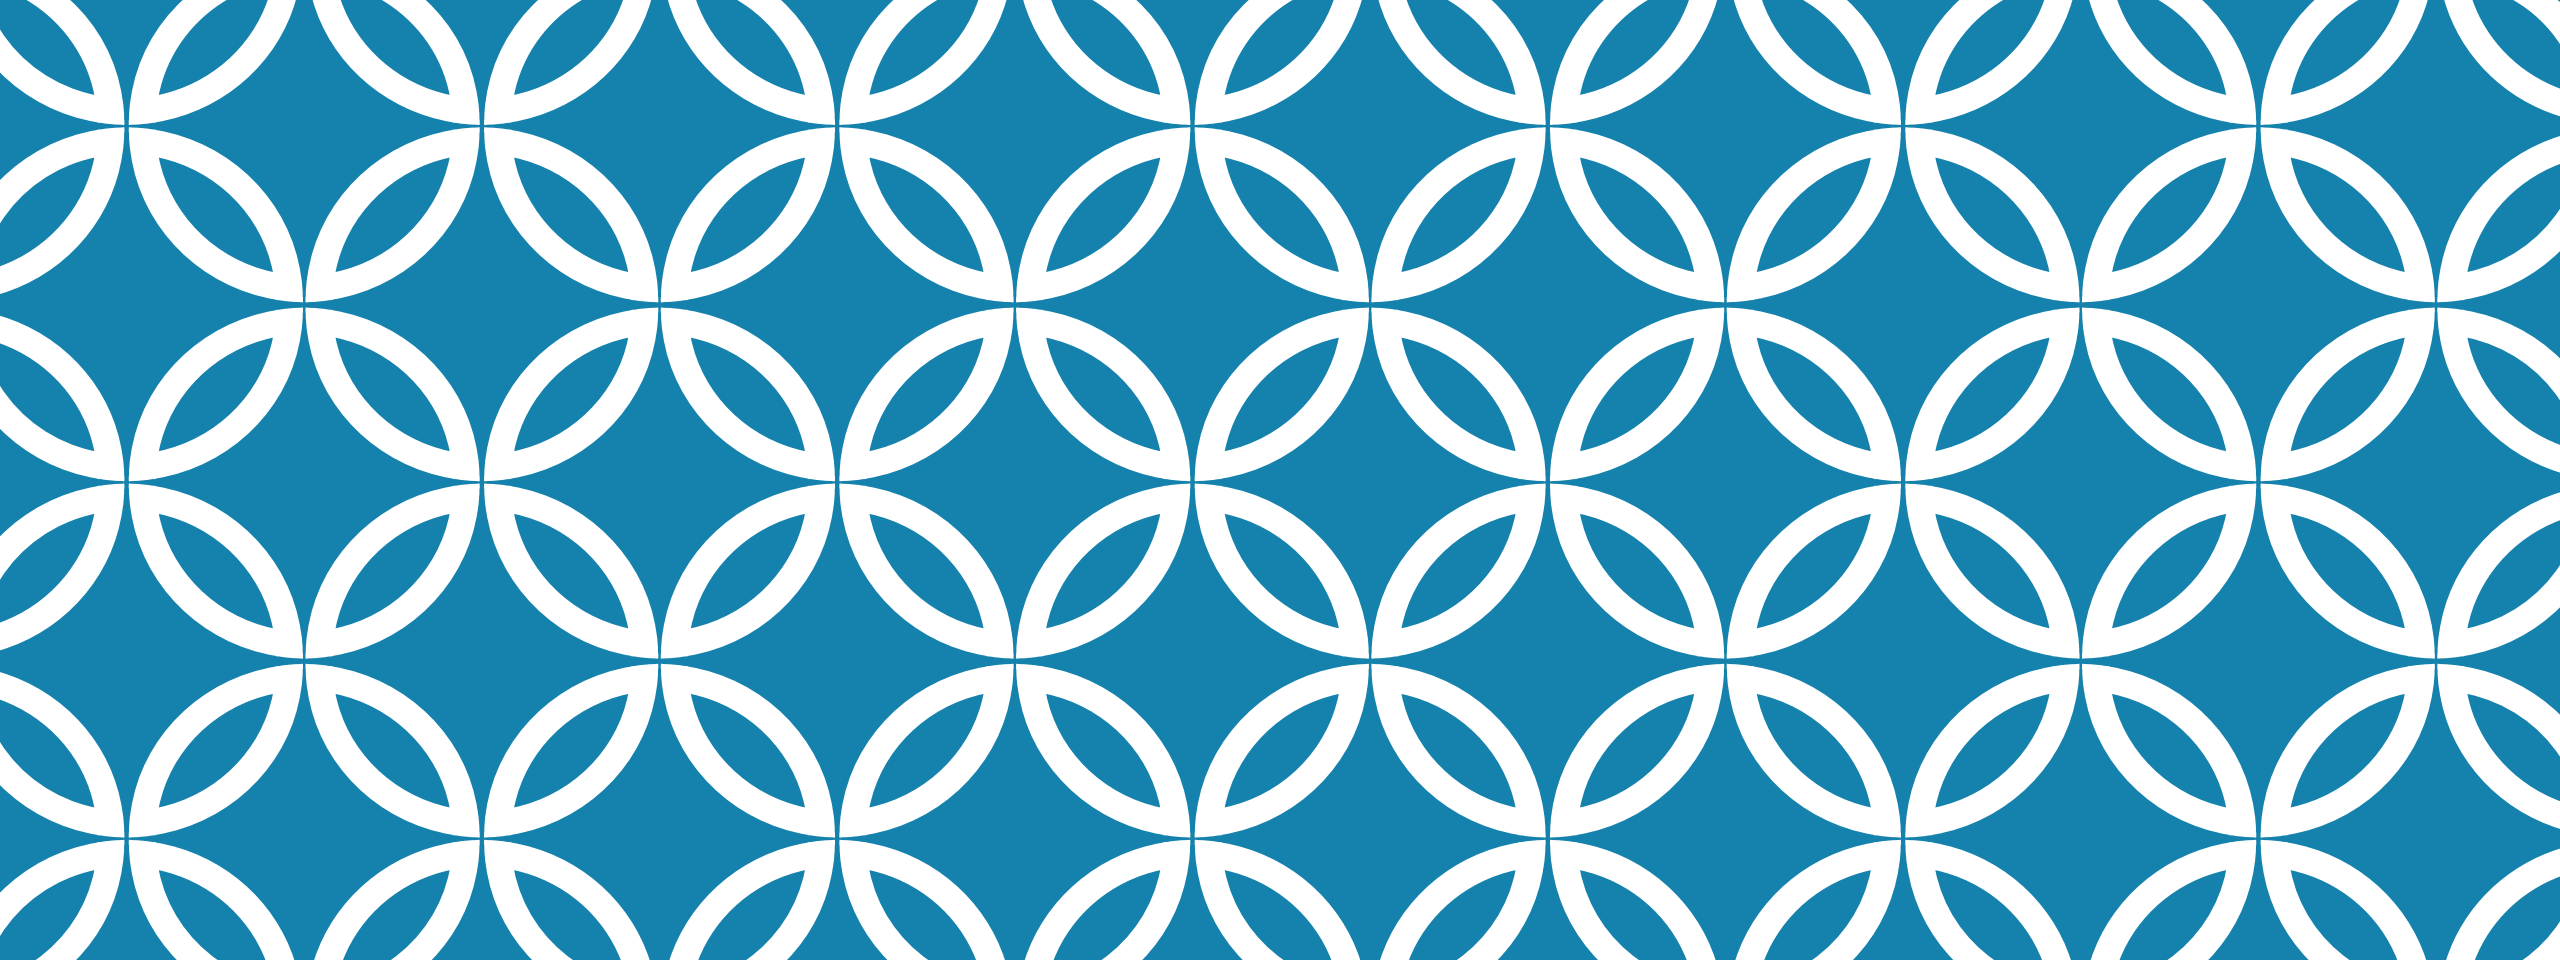
Conclusion et perspectives

Conclusion

- Présentation de méthodologie **data-driven** permettant d'identifier des pays à fort potentiel d'implantation.
- Sélection rigoureuse des **indicateurs pertinents pour le projet**
- Proposition d'un **scoring basé sur l'intervalle interquartile** : neutraliser les valeurs extrêmes
- Classement final des pays **ciblant les besoins** d'Academy :
  - Accès à l'éducation,
  - Qualité du système éducatif,
  - Environnement économique stable.

Perspectives

- **Pondérations ajustables** selon la stratégie d'Academy.
- Approche **machine learning** pour prédire le potentiel futur des pays



Merci pour votre attention

Faïza Khelladi